



UNIFOR

**UNIVERSIDADE DE FORTALEZA
CENTRO DE CIÊNCIAS TECNOLÓGICAS
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO**

VICTOR ALVES MEDEIROS

**COMPARAÇÃO DE ENSEMBLES PARA PREVISÃO DE EMBARQUE DE
PASSAGEIROS DE ÔNIBUS**

FORTALEZA – CEARÁ

2021

VICTOR ALVES MEDEIROS

COMPARAÇÃO DE ENSEMBLES PARA PREVISÃO DE EMBARQUE DE PASSAGEIROS
DE ÔNIBUS

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Centro de Ciências Tecnológicas da Univer-
sidade de Fortaleza, como requisito parcial à
obtenção do grau de bacharel em Ciência da
Computação.

Orientador: Prof. Dr. Carlos Caminha

FORTALEZA – CEARÁ

2021

Ficha catalográfica da obra elaborada pelo autor através do programa de geração automática da Biblioteca Central da Universidade de Fortaleza

Medeiros, Victor.

COMPARAÇÃO DE ENSEMBLES PARA PREVISÃO DE EMBARQUE DE
PASSAGEIROS DE ÔNIBUS / Victor Medeiros. - 2021
80 f.

Trabalho de Conclusão de Curso (Graduação) - Universidade
de Fortaleza. Curso de Ciência Da Computação, Fortaleza, 2021.
Orientação: Carlos Caminha.

1. previsão. 2. ônibus. 3. aprendizado de máquina. 4.
ensemble. 5. embarque de passageiros. I. Caminha, Carlos. II.
Título.

VICTOR ALVES MEDEIROS

COMPARAÇÃO DE ENSEMBLES PARA PREVISÃO DE EMBARQUE DE PASSAGEIROS
DE ÔNIBUS

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Centro de Ciências Tecnológicas da Univer-
sidade de Fortaleza, como requisito parcial à
obtenção do grau de bacharel em Ciência da
Computação.

Aprovada em: 09 de Dezembro de 2021


BANCA EXAMINADORA



Prof. Dr. Carlos Caminha (Orientador)
Centro de Ciências Tecnológicas - CCT
Universidade de Fortaleza - UNIFOR



Prof. Dr. Rilder de Sousa Pires
Centro de Ciências Tecnológicas - CCT
Universidade de Fortaleza - UNIFOR



Prof. Me. Caio César Ponte Silva
Ciências Tecnológicas - CCT
Universidade de Fortaleza - UNIFOR

A Deus. Aos meus pais, José Juscelino e Irma
Alves.

AGRADECIMENTOS

À Coordenação do curso de Ciência da Computação, em especial às professoras Aline Maria Matos Rocha, Sandra Freitas Ferreira Lima e Liadina Camargo Lima pelo apoio durante a disciplina de TCC1. Ao Prof. Dr. Carlos de Oliveira pelo constante apoio, disponibilidade e paciência ao guiar o trabalho. Aos professores participantes da banca examinadora pelas contribuições e sugestões de melhoria. É um valioso adendo a mencionar os professores Eriko Webert de Oliveira Araújo e Maria Andréia Formico Rodrigues, que, assim como o professor Carlos, me inspiraram com suas atitudes entusiásticas, verdadeiros exemplos de docência.

Aos colegas de curso pela parceria e contribuições indiretas ao trabalho durante disciplinas de tema similar.

À minha família pelo suporte e incentivo, pois, sendo da mesma área de atuação - tanto meu pai, José Juscelino Barbosa Medeiros, quanto minha mãe, Irma Alves Ferreira Medeiros -, pôde me ajudar de forma prática em importantes momentos da elaboração deste trabalho. Aos meus grandes amigos e amigas que me acompanharam durante toda a jornada nos baixos e altos.

“Eu enfrentarei meu medo. Permitirei que passe por cima e me atravesse. E, quando tiver passado, voltarei o olho interior para ver seu rastro. Onde o medo não estiver mais, nada haverá. Somente eu permanecerei.”

(Duna - Frank Herbert)

RESUMO

Muitas pesquisas têm sido desenvolvidas no campo de aprendizado de máquina e uma das estratégias de previsão que mais tem se destacado é a de *Ensembles*, combinações de diferentes modelos chamados de “modelos fracos” ou “modelos base” para a criação de um modelo mais forte. Devido aos bons resultados nessas pesquisas, vê-se a necessidade de investigar suas aplicações em áreas de benefício à sociedade, e este trabalho demonstra tal fato ao efetuar previsões de embarque de passageiros no sistema de transporte público da região metropolitana de Fortaleza. Recolhemos dados gerados pelo sistema de transporte de ônibus da Secretaria de Infraestrutura de Fortaleza e pela ETUFOR (Empresa de Transporte Urbano de Fortaleza), e após devida higienização e ajuste na estrutura dos mesmos, foram efetuadas as modelagens e a seleção de características para o alvo do problema em questão. Por fim, para elencar o melhor método de *Ensemble* em previsões de embarque de passageiros, foi realizada uma avaliação dos modelos de aprendizado de máquina de *Stacking*, *Bagging* e *Boosting*.

Palavras-chave: previsão. passageiros. ônibus. aprendizado de máquina. *ensembles*. *stacking*. *bagging*. *boosting*. regressão linear. *random forest*.

ABSTRACT

Many researches have been developed in the machine learning field using a plethora of techniques and a good sum of it not only relying on statistical models but on ensemble models as well. Due to the great results provided by these researches the necessity to apply such methods to areas that would benefit society rises and this work demonstrates that need by applying those models to predict the passenger onboarding on the public transport system of Fortaleza's metropolitan region. We collected data generated by the bus transport system of the Secretariat of Infrastructure of Fortaleza and ETUFOR (Urban Transport Company of Fortaleza), and after proper cleaning and adjustment in their structure, then modeling and selection of features for the target of the problem in question, machine learning models with ensemble approaches like Stacking, Bagging and Boosting were applied to find out the best model to predict the passenger boarding on a specific busline, on a specific day of the week and at a specific time of day.

Keywords: prediction. passenger flow. bus. machine learning. ensembles. stacking. bagging. boosting. linear regression. random forest.

LISTA DE ILUSTRAÇÕES

Figura 1 – Aprendizado Supervisionado.	23
Figura 2 – Problema de classificação à esquerda e problema de regressão, dados sintéticos sem representatividade ou contexto.	24
Figura 3 – (a) Modelo Linear e (b) Modelo Não Linear .	25
Figura 4 – Fórmula de estimativas em regressão linear.	26
Figura 5 – Exemplo sintético, ilustrando a decisão de como seria o clima de um dia dadas as condições necessárias.	27
Figura 6 – Árvore de Decisão construída sobre os dados de Íris (1936) de UCI ML Repository. Mostrando a probabilidade do tipo de íris dependendo de características como largura e comprimento da pétala.	27
Figura 7 – Estrutura de processo de um modelo tradicional sem <i>ensemble</i>.	28
Figura 8 – Estrutura de processo de um modelo com a técnica de <i>ensemble</i> utilizando aprendizado em paralelo.	29
Figura 9 – Fórmulas das métricas de erro.	31
Figura 10 – Quantidade de embarques por hora, da linha 041 Parangaba/Oliveira Paiva (novembro de 2015).	38
Figura 11 – Soma total de validações por hora em todo o conjunto de dados no arquivo de validações.	40
Figura 12 – Representação da combinação do Seno e Cosseno da Hora do embarque. A) Cosseno da Hora , B) Seno da Hora e C) sendo a representação conjunta de A e B	41
Figura 13 – Sazonalidade de quantidade de embarque de passageiros em dias úteis.	42
Figura 14 – Sazonalidade de quantidade de embarque de passageiros em finais de semana.	42
Figura 15 – Sazonalidade de quantidade de embarque de passageiros por dia do mês.	43
Figura 16 – Sazonalidade de quantidade de embarque de passageiros por semana do mês.	44
Figura 17 – Comparativo de quantidade de embarque entre junho e julho de 2015.	45
Figura 18 – Ilustração da diferença de quantidade de embarque de passageiros no período de feriado de carnaval em fevereiro de 2015.	46

Figura 19 – Comparativo de quantidade de embarques entre as 50 linhas com mais fluxo. Em destaque a linha 041 - PARANGABA / OLIVEIRA PAIVA / PAPICU	
.....	48
Figura 20 – Gráfico de previsão do dia 1º de abril de 2015 em um modelo treinado com os dados dos meses de janeiro, fevereiro e março de 2015 utilizando Regressão Linear.	49
Figura 21 – Gráfico de previsão do dia 1º de abril de 2015 em um modelo treinado com os dados dos meses de janeiro, fevereiro e março de 2015 utilizando Ridge Regression.	50
Figura 22 – Resultados de métricas de erro para o modelo de árvore de decisão, treinado com janeiro, fevereiro e março de 2015 prevendo: 1º de abril, 5 de maio, 10 de novembro.	52
Figura 23 – Resultados de métricas de erro para o modelo de Bagging de árvores de decisão, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro.	54
Figura 24 – Resultados de métricas de erro em previsões para o modelo de Random Forest, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro.	56
Figura 25 – Resultados de métricas de erro em previsões para o modelo de <i>extreme Gradient Boosting</i>, treinado com janeiro, fevereiro e março de 2015prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro	59
Figura 26 – Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	61
Figura 27 – Resultados da previsão da primeira semana de dezembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a novembro	62

Figura 28 – linha 45 - Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	72
.....	
Figura 29 – linha 003 - Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	73
.....	
Figura 30 – linha 42 - Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	74
.....	
Figura 31 – linha 51 - Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	75
.....	
Figura 32 – linha 52 - Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	76
.....	
Figura 33 – linha 24 - Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	77
.....	
Figura 34 – linha 76 - Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	78
.....	
Figura 35 – linha 26 - Resultados da previsão da primeira semana de novembro de 2015, no modelo <i>Stacking eGB</i> treinado com os meses de janeiro a outubro	79
.....	

Figura 36 – linha 44 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro

..... 80

LISTA DE TABELAS

Tabela 1 – Descrição e exemplificação da organização dos dados utilizados no projeto.	
.....	37
Tabela 2 – Resultados de métricas de erro em previsões utilizando modelos lineares.	
.....	50
Tabela 3 – Resultados da previsão com árvore de decisão.	51
Tabela 4 – Resultados da previsão com <i>Bagging</i> de árvores de decisão.	53
Tabela 5 – Resultados da previsão com <i>Random Forest</i>.	55
Tabela 6 – Resultados de métricas de erro em previsões utilizando os modelos: árvore de decisão, <i>Random Forest</i> Padrão e <i>Bagging</i> de arvores de decisão.	
.....	57
Tabela 7 – Resultados de métricas de erro em previsões para o modelo utilizando <i>Stacking</i>, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro	
.....	57
Tabela 8 – Resultados de métricas de erro em previsões para o modelo utilizando <i>extreme Gradient Boosting</i>, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro	
.....	58
Tabela 9 – Resultados de métricas de erro em previsões para o modelo <i>Stacking</i> A com adição do modelo de <i>extreme Gradient Boosting</i>, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro	
.....	60
Tabela 10 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro,fevereiro e março de 2015 e prevendo o dia 10 de novembro.	
.....	63

Tabela 11 – Alteração nos dados de treinamento, com o modelo <i>Stacking eGB</i>, prevendo o dia primeiro de abril de 2015.	
.....	65
Tabela 12 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 045 CONJUNTO CEARÁ / PAPICU / MONTESE.	
.....	71
Tabela 13 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 003 IPARANA / VIA PARQUE LEBLON.	
.....	72
Tabela 14 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 042 ANTÔNIO BEZERRA / FRANCISCO SÁ / PAPICU.	
.....	73
Tabela 15 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 051 Grande Circular I.	
.....	74
Tabela 16 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 052 GRANDE CIRCULAR II.	
.....	75
Tabela 17 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 024 ANTÔNIO BEZERRA / LAGOA / UNIFOR.	
.....	76

Tabela 18 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 076 CONJUNTO CEARÁ / ALDEOTA / PAPICU.

..... 77

Tabela 19 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 026 ANTÔNIO BEZERRA / MESSEJANA.

..... 78

Tabela 20 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 044 PARANGABA / PAPICU / MONTESE.

..... 79

LISTA DE ABREVIATURAS E SIGLAS

CSV	<i>Comma Separated Values</i>
ETUFOR	Empresa de Transporte Urbano de Fortaleza
GPS	<i>Global Positioning System</i> ou Sistema de Posicionamento Global
SVR	<i>Support Vector Regression</i>
XGBoost	<i>extreme Gradient Boosting</i>

SUMÁRIO

1	INTRODUÇÃO	18
1.1	JUSTIFICATIVA	20
1.2	OBJETIVOS	20
1.3	ESTRUTURA DO TRABALHO	21
2	ESTADO DA ARTE	22
2.1	FUNDAMENTAÇÃO TEÓRICA	22
2.2	TRABALHOS RELACIONADOS	31
3	METODOLOGIA	36
3.1	FERRAMENTAS	36
3.2	BASE DE DADOS	36
3.3	HIGIENIZAÇÃO E TRANSFORMAÇÃO DOS DADOS	38
3.4	EXEMPLO DE ESTUDO	39
3.5	ENGENHARIA DE <i>FEATURES</i>	39
3.6	MODELAGEM PARA APRENDIZADO DE MÁQUINA	47
4	RESULTADOS	48
5	CONCLUSÕES	64
5.1	CONTRIBUIÇÕES DO TRABALHO	64
5.2	LIMITAÇÕES	64
5.3	TRABALHOS FUTUROS	65
	REFERÊNCIAS	67
	APÊNDICES	70
	APÊNDICE A – Resultados do modelos aplicados nas linhas de ônibus mais utilizadas	71

1 INTRODUÇÃO

Aprendizado de máquina, definido em 1959 por Arthur Samuel como o "campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados", está em constante evolução e inovação. Tal campo de estudo possui diversas aplicações dentro da sociedade, com pesquisas buscando compreender melhor a grande quantidade de dados que o mundo possui. A observação de padrões, de classificações e de previsões de dados são atividades bastante exploradas, e pode-se compreender a extensão de possíveis aplicações deste campo ao observar trabalhos notórios, como uma modelagem de aprendizado de máquina capaz de classificar tipos de câncer de mama (AMRANE *et al.*, 2018), modelagens dentro do campo de *Internet of Things* aplicando um algoritmo de aprendizado para o balanceamento entre experiência de usuário e economia de equipamentos (PONTE *et al.*, 2019) e outros trabalhos como *Explaining machine learning models in sales predictions* (BOHANEK; BORŠTNAR; MARKOROBNIK-ŠIKONJA, 2017), que detalha os modelos de aprendizado de máquina aplicados a previsão de vendas entre diversos negócios.

Dentre os grandes passos que já foram dados dentro deste campo, podem-se citar os métodos de aprendizado de máquina utilizando *Ensembles*, que podem ser definidos como um comitê ou conjunto de máquinas de aprendizado que de alguma forma, para cada tipo de *ensemble*, combinam suas previsões e chegam a uma previsão única para um problema em questão (POLIKAR, 2012). Cada método pode ser encontrado em pesquisas como (HAUSSLER; KEARNS; SCHAPIRE, 1994), (HO, 1995) e (WOLPERT, 1992), e suas primeiras caracterizações como modelos de "*ensemble*" podem ser encontradas, por exemplo, em (DIETTERICH, 1998) e (OPITZ; MACLIN, 1999). A combinação de múltiplos preditores ao invés de apenas um "melhor" preditor é uma técnica bem estabelecida no estado da arte, utilizada não somente no campo da ciência de dados e aprendizado de máquina, tendo em vista que é bastante conhecido no campo da estatística, e referenciado em diversas publicações como Rao e Subrahmaniam (1971), Efron e Morris (1973), Rubin e Weisberg (1975), Berger e Bock (1976) e Green e Strawderman (1991).

Os modelos de *ensemble* avaliados neste trabalho são: *Bagging*, *Boosting* e *Stacking*, e todos seguem as definições de *ensembles*, com algumas pequenas diferenças em como os comitês são formados. Por exemplo, em *bagging* tem-se uma agregação de vários modelos iguais, já em *stacking*, além de possuírem modelos diferentes compondo tal comitê, um modelo é escolhido como base ou estimador final, cuja previsão ou votação possui peso diferente na

previsão. O modelo de *boosting*, similarmente a técnica de bagging, é composto de modelos homogêneos entretanto estes são treinados de forma sequencial para uma melhoria continua ate a previsão final. Durante a fundamentação teórica desta pesquisa mais detalhes são revelados acerca do funcionamento destas técnicas.

Sabendo dos grandes benefícios que as técnicas de *ensemble* trazem ao campo de aprendizado de máquina, este trabalho busca aplicar algumas dessas técnicas no domínio de sistemas de transporte públicos, que pode se aproveitar da melhora de previsões em alguns contextos. Como apresentado em held-2018, os meios de transporte público geram grandes vantagens socioeconômicas e socioambientais, tais como redução de poluições auditiva, visual e do ar, além de evitar problemas como consumo de recursos finitos para manter transportes individuais ou de capacidade de passageiros reduzida. "Por isso, é necessário um bom planejamento a fim de incentivar o uso desses sistemas, que atenda de forma efetiva o usuário, tendo um sistema bem infraestruturado e acessível a todos"(MAZZULLA; EBOLI, 2006).

Pela preocupação em atingir métricas de satisfação e garantir que o transporte público seja de fato utilizado pela população, já existem extensas pesquisas, metodologias e estudos que procuram abranger os aspectos necessários para atingir tais métricas. De acordo com (CEDER; H.M.WILSON, 1986), percebe-se, de forma geral, que a satisfação do usuário final está diretamente ligada aos pontos mencionados anteriormente, como, por exemplo, um bom desenho de rotas - otimizando o tempo em cada viagem - e agendamento de veículos e de equipes - tornando o serviço mais acessível para um número maior de pessoas. Sendo assim, situações como superlotação dos veículos e disponibilidade precária são aspectos negativos que tendem a ser reduzidos. Um bom planejamento traz à tona esses pontos e muitas são as variáveis que compõem a tomada de decisão para o cumprimento de cada uma das tarefas referenciadas previamente.

Neste sentido, este trabalho pretende, através da utilização de *Ensembles* de máquinas de aprendizado, processar e avaliar os dados recentes de mobilidade urbana do transporte público de ônibus da cidade de Fortaleza, Ceará, de modo a buscar a previsão da demanda por esses serviços de transporte pela população. Esta aplicação torna-se, naturalmente, uma avaliação dos modelos e pode-se concluir quais se destacam nas previsões dentro do domínio proposto.

1.1 JUSTIFICATIVA

O estudo de comparações de modelos de *ensemble* possui um bom espaço a ser preenchido no estado da arte no campo de aprendizado de máquina em geral.

Essencialmente, devido à boa performance observada de tais modelos e técnicas, a sua exploração comparativa se torna importante para o desenvolvimento de projetos, tanto em soluções de mercado - apresentando os modelos mais adequados para problemas de natureza similar aos do domínio estudado neste trabalho -, quanto para o impulsionamento de pesquisas no campo - com a expansão da análise comparativa destas técnicas e como elas podem performar em conjunto para resolver um problema. Ao avaliar as capacidades de previsão destes modelos e aplicando-as aos sistemas de transportes públicos, trazem-se os benefícios destas técnicas para um domínio de relevância à sociedade, e previsões acuradas são fundamentais para este domínio que depende de um bom planejamento para seu funcionamento. A compreensão da quantidade de passageiros embarcando em um ônibus pode ajudar o planejamento do sistema em geral a otimizar os recursos disponíveis, seja em quantidade de ônibus ativos por rota ou equipes de motoristas e cobradores alocados. Tais resultados podem levar até mesmo a mudança de caminhos das rotas em si para atender melhor a demanda do sistema de transporte público.

1.2 OBJETIVOS

Esse trabalho tem como objetivo avaliar a performance de modelos de aprendizado de máquina utilizando técnicas de *ensemble* para prever o embarque de passageiros no sistema de mobilidade urbana de ônibus na cidade de Fortaleza, Ceará.

Como objetivos específicos têm-se:

- Elaborar e aplicar métodos de higienização dos dados obtidos através da Secretaria de Infraestrutura e ETUFOR (Empresa de Transporte Urbano de Fortaleza);
- Identificar as métricas e componentes dos dados mais importantes para os modelos de aprendizado de máquina;
- Aplicar modelos de aprendizado de máquina para prever a demanda específica abordada pelo trabalho;
- Aplicar métodos de medidas de taxas de erro para validação dos experimentos feitos.

1.3 ESTRUTURA DO TRABALHO

Este trabalho é organizado da seguinte maneira: no Capítulo 2, são demonstrados aspectos e definições que compõem o campo da computação de aprendizado de máquina, bem como uma série de artigos que apresentam a validade dos estudos relacionados aos temas tratados. No Capítulo 3, são descritos os métodos utilizados na parte prática da pesquisa, entrando em detalhes sobre como o dado estudado é tratado e organizado para a aplicação dos modelos de aprendizado de máquina propostos. A seguir, no Capítulo 4, são explicitadas as aplicações dos modelos e a análise das informações obtidas e, no Capítulo 5, são traçadas as conclusões da pesquisa e apresentadas possíveis sugestões de informações adquiridas em seus resultados.

2 ESTADO DA ARTE

Este capítulo está dividido em duas seções. Na primeira, temos as descrições dos métodos estatísticos e de aprendizado de máquina utilizados, bem como a descrição da natureza dos dados analisados. Em seguida, na segunda seção, temos os artigos relacionados ao tema em questão, pesquisas e trabalhos que demonstram a utilidade do mesmo, bem como das ferramentas e métodos utilizados neste trabalho.

2.1 FUNDAMENTAÇÃO TEÓRICA


Aprendizado de máquina é o estudo de algoritmos de computadores que melhoram automaticamente através da experiência adquirida. Este campo da ciência da computação procura responder perguntas tal qual “como a performance de algo pode mudar dependendo da quantidade de exemplos utilizados?”. Esse estudo pode ser formalmente definido como a busca de se melhorar uma performance P , de uma tarefa T através da apresentação de experiências de treino E (MITCHELL, 1997). É possível “alimentar” o computador com dados de várias formas e modelá-lo de modo que este seja capaz de identificar padrões, grupos e comportamentos para que possa, depois de treinado, classificar e extrair mais informações. Entrando em detalhes, o aprendizado de máquina pode ser dividido em três tipos:

(1) Aprendizado Supervisionado: acontece quando os dados de treinamento inseridos no modelo possuem exemplos corretos de *outputs* (saídas) para os devidos *inputs* (entradas). Como, por exemplo, um conjunto de dados de treinamento para números escritos à mão e os valores digitalizados de cada um. O conjunto possui então imagem e dígito como treinamento para o modelo. Este poderia, após o treinamento, ser capaz de identificar o dígito correto de uma imagem cujo conteúdo seja um número escrito à mão.

(2) Aprendizado por Reforço: ocorre quando os dados de treinamento não possuem explicitamente o *output* (saída) correto para cada *input* (entrada). Como não se está mais em um ambiente supervisionado no conjunto de dados de treinamento, temos agora a entrada, uma possível saída e uma nota para essa saída, como uma medição de performance do quão satisfatório seria aquele *output* (saída).

(3) Aprendizado não Supervisionado: neste caso não se faz presente nenhum tipo de *output* no conjunto de dados de treinamento. Esta forma de aprendizado é utilizada para categorizar dados, encontrar padrões e estrutura dentro dos *inputs* que compõem o conjunto de dados de treinamento (ABU-MOSTAFA, 2012).


Figura 1 – Aprendizado Supervisionado.



Fonte – Elaborada pelo autor

No decorrer desta pesquisa serão aplicados os conceitos e métodos relacionados ao tipo **Aprendizado Supervisionado**, explicado acima e ilustrado na Figura 1. Este pode ser categoricamente dividido, de forma geral, em dois tipos de problemas exemplares: **(1) Problemas de Regressão** e **(2) Problemas de Classificação**. O primeiro envolve a identificação de padrões de valores em um espectro contínuo, para efetuar uma previsão com certa acurácia. No segundo tipo, por sua vez, a informação é dividida de forma discreta, em categorias, cuja identificação depende do modelo implementado (JAIN; DUIN; MAO, 2000). Os modelos utilizados para resolver os exemplos descritos acima, ao serem treinados, se tornam o que chamamos de **hipóteses**, e estas geram aproximações da função alvo e o mapeamento dos *inputs* e *outputs*. Isto é o aprendizado em si: a procura, no espaço de hipóteses possíveis, daquela que possui melhor performance em novos exemplos além do conjunto de dados de treinamento (RUSSELL; NORVIG, 2009).

Figura 2 – Problema de classificação à esquerda e problema de regressão, dados sintéticos sem representatividade ou contexto.




Fonte – Elaborada pelo autor

A Figura 2 ilustra a diferença entre problemas de classificação e problemas de regressão. À esquerda da figura tem-se um exemplo de um problema de classificação no qual a linha pontilhada vermelha, representando o modelo gerado, consegue separar as bolas azuis das cruzeiras roxas. Ou seja, o modelo consegue identificar tipificações dentro de um conjunto de dados. No lado direito da figura tem-se o exemplo de regressão, em que as bolas azuis representam as previsões feitas pelo modelo e a linha pontilhada em vermelho representa o modelo obtido dadas as circunstâncias de treinamento.

As hipóteses, se representadas graficamente, podem exemplificar os tipos de propostas dos modelos, e são categorizadas em lineares e não lineares. Na Figura 3 pode-se observar, para um mesmo problema, hipóteses diferentes geradas por modelos diferentes, estes sendo (a) Regressão Linear e (b) *Random Forest*. As bolas azuis representam os exemplos de previsão e a reta em (a) representa o modelo gerado no treinamento, que sendo de natureza linear, procura representar o problema em uma linha reta. Já em (b), a linha pontilhada vermelha representa o problema de forma mais adequada, pois possui um modelo não-linear. A seguir são apresentados exemplos nos quais foram utilizados dados sintéticos gerados de forma arbitrária.

Figura 3 – (a) Modelo Linear e (b) Modelo Não Linear .



Fonte – Elaborada pelo autor

Como detalhado na pesquisa, serão efetuadas previsões de demandas no sistema de transporte público de Fortaleza, ou seja, o tipo de problema desta pesquisa é de **regressão**. Problemas de regressão podem ser resolvidos através de diversos modelos, e, dentre eles, é importante citar os seguintes:

(1) **Regressão Linear**: sua forma é explicada como a relação entre variáveis X e Y em uma fórmula linear. Sendo X as *features* do modelo, podemos ter mais de uma na fórmula variante:

$$Y = AX + B \quad (2.1)$$

$$Y = A_1X_1 + A_2X_2 + \dots + A_nX_n + B \quad (2.2)$$

Observa-se na Fórmula 2.1 a definição para um modelo com 1 *feature*, e na Fórmula 2.2 a definição com múltiplas *features*, onde A e B são constantes representando o declive da linha reta e a intersecção do eixo Y, respectivamente. Estimativas dos valores de A e B podem ser obtidas através da aplicação dos métodos dos mínimos quadrados, resultando na seguinte fórmula ilustrada pela Figura 4:

Figura 4 – Fórmula de estimativas em regressão linear.

$$A = \frac{\sum(X_i Y_i) - N \langle X \rangle \langle Y \rangle}{\sum(X_i^2) - N \langle X \rangle^2}$$

$$B = \langle Y \rangle - A \langle X \rangle$$


Fonte – Elaborada pelo autor

X_i e Y_i são os valores de entrada e saída, respectivamente, de um exemplo do conjunto de dados, N é o número de observações ou ocorrências, $\langle X \rangle$ e $\langle Y \rangle$ são as médias das N observações. Este modelo se provou ao longo do tempo um excelente método estatístico para previsões (DISKIN, 1970).

(2) Árvore de Decisão: Esta forma de aprendizado é um método para aproximar valores, normalmente, discretos de funções sobre o alvo de previsão, no qual a função de aprendizado é representada por uma árvore de decisão. De forma mais simples, as árvores podem ser lidas como conjuntos de “se...então” onde, partindo do nó raiz, seguindo uma série de chaveamentos, chega-se na previsão esperada. Cada nó na árvore especifica um teste de um atributo do exemplo de entrada para previsão e outros testes subsequentes para cada ramo descendente. Um exemplo recebe sua previsão ou classificação pela ordenação adentrando a árvore de decisão pelos nós apropriados (MITCHELL, 1997).


As Figuras 5 e 6 exemplificam uma maneira adequada de se observar a árvore de decisão que pode ser gerada. A Figura 5 ilustra um exemplo de árvore de decisão classificando o clima de um determinado dia dadas as condições apresentadas. A Figura 6, por sua vez, ilustra uma árvore de decisão em um problema de classificação de tipos de Íris, um gênero de plantas com flores, e, nesta visualização, no canto inferior esquerdo de cada bloco, tem-se a probabilidade de cada tipo de Íris cujos ramos da árvore e bifurcações definem as decisões tomadas dadas certas características da Íris (*petal width* - largura da pétala, *petal-length* - comprimento da pétala).

Figura 5 – Exemplo sintético, ilustrando a decisão de como seria o clima de um dia dadas as condições necessárias.



Fonte – Elaborada pelo autor

Figura 6 – Árvore de Decisão construída sobre os dados de Íris (1936) de UCI ML Repository. Mostrando a probabilidade do tipo de íris dependendo de características como largura e comprimento da pétala.




Fonte – Elaborada pelo autor

Apesar dos exemplos ilustrados serem de problemas de classificação, a lógica e organização ilustrada se aplica igualmente para métodos tradicionais de problemas de regressão, entretanto, existem outras abordagens nesta árvore de conhecimento que propõem soluções utilizando métodos de *Ensemble Learning*, que podem ser traduzido por “aprendizado de máquina por conjuntos” ou “comitês”.


Ensemble Learning é um paradigma do aprendizado de máquina que pode trazer grandes vantagens para os modelos em diversos problemas, como os apresentados e estudados em (HUANG; XIE; XIAO, 2009). Pode-se definir esse paradigma formalmente como: um sistema de aprendizado de máquina que é construído com um conjunto ou comitê de modelos individuais trabalhando em paralelo (*bagging* e *stacking*) ou sequencialmente (*boosting*), cujos *outputs* são combinados e fundidos para produzir uma única saída para o problema em questão.

Figura 7 – Estrutura de processo de um modelo tradicional sem *ensemble*.



Fonte – Elaborada pelo autor

Figura 8 – Estrutura de processo de um modelo com a técnica de *ensemble* utilizando aprendizado em paralelo.



Fonte – Elaborada pelo autor

As Figuras 7 e 8 ilustram a diferença entre os dois tipos de técnica e demonstram visualmente como o comitê se organiza dentro dos modelos utilizados. Pode-se listar, para a construção de um ensemble, 3 etapas (SANTOS; SABOURIN; MAUPINB, 2009):

- Geração das máquinas de aprendizado;
- Filtragem e seleção das máquinas de aprendizado durante o treinamento dos modelos;
- Composição das máquinas de aprendizado.

Para esta pesquisa, serão aplicados 3 tipos de *ensembles*:

- **Bagging:** Este método agrega múltiplas versões de modelos previsíveis - como, por exemplo, regressores - para gerar um único preditor. A agregação calcula a média entre as versões dos modelos para poder emitir a saída única (BREIMAN, 1996). Pode-se citar como um exemplo popular entre as técnicas de *bagging* o modelo de *Random Forest*, se comportando como uma agregação de árvores

de decisão onde os chaveamentos, com aplicação de cálculos de entropia e desordem, são selecionados para a tomada de decisões e efetivação de previsões (MITCHELL, 1997);

- **Stacking:** Esta estratégia utiliza a combinação linear de previsões para aumentar a acurácia da previsão final. A ideia geral é efetuar uma validação cruzada dos dados e mínimos-quadrados (não negativos) para determinar os melhores coeficientes para as combinações (BREIMAN, 1996);
- **Boosting:** Esta técnica mantém um conjunto de pesos sobre o conjunto de dados de treinamento em suas *features* e, utilizando de múltiplos preditores, novos dados de treinamento com pesos otimizados são fornecidos a um previsor base ou preditor principal, essencialmente, impulsionando a performance de um preditor escolhido utilizando outros preditores (DIETTERICH, 1998).

Tais modelos e técnicas foram escolhidos para citação devido a sua constante utilização nos artigos de mais relevância para esta pesquisa.

Apesar de todo o contexto de uma disciplina do campo de ciências exatas, não se espera que uma função ou modelo de aprendizado de máquina, quando aplicado a dados reais, funcione perfeitamente. Para contornar este tipo de situação, é necessário estabelecer medidas de erro confiáveis e contextualizadas, ou seja, o quão importante é a margem de erro para o problema em questão. Em *Performance Metrics (Error Measures) in Machine Learning Regression, Forecasting and Prognostics: Properties and Typology* de Alexei Botchkarev publicado em 2018, é feito um comparativo da popularidade e utilização das métricas de erro utilizadas na literatura de aprendizado de máquina em problemas de regressão.

Como resultado do comparativo no decorrer dos anos, nota-se a presença majoritária de 3 métricas, em ordem de popularidade decrescente: (1) **Mean Absolute Percentage Error (MAPE)**, (2) **Mean Absolute Error (MAE)**, (3) **Mean Square Error (MSE)** ou **Root Mean Square Error (RMSE)**, e devido à popularidade através de trabalhos avaliativos também pode-se adicionar a métrica **R²** (também conhecida como coeficiente de determinação). Estes métodos podem ser descritos matematicamente como ilustrado na Figura 9.

Figura 9 – Fórmulas das métricas de erro.

Legenda: n = tamanho do conjunto de dados, A_j - valores reais, P_j - valores previstos, $e_j = A_j - P_j$ - erro, y = valor de previsão, y_m = média das previsões, y_b = melhor valor de previsão.

$MAE = 1 / n \left(\sum_{j=1}^n e_j \right)$
$MAPE = 100 / n \sum_{j=1}^n e_j / A_j $
$MSE = 1 / n \sum_{j=1}^n (e_j)^2$
$RMSE = \sqrt{MSE}$
$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - y_m)^2}{\sum_{i=1}^n (y_i - y_{ib})^2}$

Fonte – Elaborada pelo autor

Serão utilizadas nesta pesquisa as métricas de erro descritas anteriormente para a avaliação dos modelos utilizados no experimento e desenvolvimento.

2.2 TRABALHOS RELACIONADOS

A literatura de *machine learning* (aprendizado de máquina) está repleta de conteúdo, e um dos primeiros trabalhos utilizando técnicas preditivas foi apresentado por Cooper (COOPER *et al.*, 1996), aplicando tais métodos para prever a mortalidade causada pela pneumonia em certos pacientes. Tal trabalho atualmente é citado em outros estudos relacionados a previsões sobre o COVID19, que procuram aplicar metodologias de aprendizado de máquina para prever dados clínicos sobre o vírus, como em Schwab (SCHWAB *et al.*, 2020). Outros trabalhos que se pode mencionar dentro do mesmo contexto é (PONTE *et al.*, 2021) que estuda a exposição dos usuários de transporte público ao COVID19 e (??) que trata do estudo de trajetórias *indoor*.

Considerando o tema abordado neste trabalho, se tem como referência de artigo relacionado: em Wang (WANG *et al.*, 2020) - visando ajudar a resolver problemas em potencial de meios de transporte como congestionamento, falta de oferta em relação a demanda de veículos, fluxo de passageiros e formas ágeis de lidar com emergências - apresentou alguns modelos *ensemble* para efetuar uma previsão de curto prazo para o fluxo de passageiros no transporte público urbano. Com os dados da linha de ônibus 428 da área de Huitian em Beijing dos dias 1º de janeiro até 31 de maio de 2020, modelos como *Multivariable Linear Regression* (MLR), *K-Nearest Neighbor* (KNN), *eXtreme Gradient Boosting* (XGBoost), e *Gated Recurrent Unit* (GRU) foram aplicados para efetuar previsões e comparados entre si. Os resultados da publicação enriquecem a área estudada e inspiram esta pesquisa trabalhada a fazer contribuição similar em Fortaleza. Semelhante ao artigo mencionado anteriormente, apesar de aplicado em outro campo social, pode-se citar, como um artigo que utiliza métodos de *ensemble*, Torres (TORRES *et al.*, 2017), que utilizou o algoritmo *superlearner* para aplicar um método de *ensemble* e prever a depressão em adultos de acordo com critérios sociais. O *superlearner* agrega um conjunto de algoritmos supervisionados, como *gradient boosted trees*, e seleciona o peso desses algoritmos de acordo com o desempenho individual alcançado. Estudos recentes como esses são fundamentais para manter técnicas com *ensembles* relevantes dentro do contexto social, e não apenas para fomentar melhorias estatísticas de modelos. Eventualmente, estes devem ser aplicados para benefícios estratégicos na comunidade que se vive.

Existem diversas pesquisas no campo de mobilidade urbana avaliando e investigando as partes fundamentais de sistemas de transporte na sociedade. Pode-se mencionar entre tantos trabalhos, alguns como Maia (MAIA *et al.*, 2021), que estuda como o impacto de padrões de planejamento urbano com semáforos no trânsito pode alterar trajetórias tomadas por veículos motorizados, e Ponte (PONTE *et al.*, 2018), que avalia como os intervalos entre viagens de ônibus dentro de suas respectivas rotas podem ser usados para caracterizar a qualidade da viagem em si.

Ao avaliar as pesquisas realizadas com aprendizado de máquina no domínio de transportes públicos, pode-se citar como artigos adequados para referências: Toqué (TOQUÉ *et al.*, 2017), no qual se propôs prever os fluxos de passageiros em curto e longo prazo das linhas de metrô utilizando métodos de aprendizado de máquina como *Random Forest*, redes neurais *Long-Short Term Memory* e modelos calendários. A previsão foi feita da seguinte maneira: quinze minutos para paradas de metrô, trinta minutos à frente para paradas de ônibus e previsões para um ano à frente, no caso de longo prazo. Os experimentos foram feitos em conjuntos de

dados de transporte de dois anos do distrito de La Défense, em Paris.

Hofleitner (HOFLEITNER; HERRING; BAYEN, 2012) apresenta uma pesquisa feita para efetuar a estimativa e previsão do fluxo de tráfego de veículos e congestionamentos em vias arteriais da cidade de São Francisco, Califórnia, nos Estados Unidos da América. Utilizando modelos de aprendizado de máquina para detectar, nos dados reais, as características mais importantes dentro das teorias de fluxo de tráfego de veículos, a pesquisa encontra sucesso em sua proposta. Através da validação que foi feita das informações obtidas, com 20 pilotos em quatro rotas distintas da cidade durante 3 dias, o modelo pôde calcular precisamente o tempo de viagem e o estado de congestionamento.

Em Miller (MILLER; HOW, 2017) foi feito um estudo sobre qualidade de serviço para o usuário final de sistemas de mobilidade sob-demanda no campus do Instituto de Tecnologia de Massachusetts (MIT). Aplicando métodos estatísticos como o de *Poisson* para prever demanda e tempo de espera destes veículos, e propondo como avanço da pesquisa aplicações de métodos de aprendizado de máquina, os pesquisadores demonstraram o sucesso da pesquisa com um aumento na satisfação do serviço e com melhor planejamento e organização dos veículos no campus, uma diminuição de 20% no tempo de espera médio. Tanto Hofleitner (HOFLEITNER; HERRING; BAYEN, 2012) quanto Miller (MILLER; HOW, 2017) representam os exemplos de benefícios para uma pesquisa na área, ao passo que também apresentam abordagens que servem de inspiração e guias para este trabalho.

Zhang (ZHANG *et al.*, 2017) alega ser o primeiro artigo publicado que utiliza base de dados separadas de GPS (*Global Positioning System* ou Sistema de Posicionamento Global) e cartões inteligentes para controle de passageiros para, através de modelos de aprendizado de máquina, prever o fluxo de passageiros em tempo real. As etapas de contribuição para o projeto foram, primeiramente, estimativa do número de passageiros que entram no ônibus em cada estação ou parada obrigatória. Após isso, utilizando os cartões inteligentes, efetuaram estimativas de quando cada passageiro iria desembarcar do veículo, e, finalmente, como terceira e última etapa, a previsão de quantos passageiros iriam embarcar no ônibus nas estações subsequentes da rota atual do veículo.

A pesquisa de Held (HELD *et al.*, 2018), por sua vez, parte do princípio de que com um melhor planejamento dos sistemas de transporte é possível efetuar uma descarbonização desse setor, reduzindo a aglomeração de veículos e viagens não otimizadas para, por consequência, reduzir a emissão em massa de CO₂-eq. Utilizando os dados de viagens da Suíça e modelos de aprendizado de máquina, as conclusões do trabalho servem como referência para trabalhos

futuros, demonstrando quais características e modelos são efetivos para estudos similares. Em Zhang (ZHANG *et al.*, 2020) foram feitos trabalhos que fogem do padrão visto até então, utilizando dados de múltiplas fontes sobre o tráfego de veículos sobre trilhos da região estudada, e levando em consideração ambos fatores temporais como espaciais para prever o fluxo de passageiros da estação de trem, além de utilizar especialmente um algoritmo de clusterização para classificar *features* de fator temporal. O autor também alega que modelos que utilizam apenas fontes singulares não possuem eficácia e precisão boas o suficiente quando comparados ao modelo de fatores espaciais e temporais. Com múltiplas menções de artigos atacando os problemas com uma variedade de modelos, percebe-se, ao redor do mundo, diversos exemplos e justificativas para pesquisas na área que podem não somente aumentar a satisfação do usuário, como também tornar o mesmo mais convidativo para outros. Maior qualidade e melhor planejamento são essenciais para sistemas de transporte com tanto impacto na comunidade estudada.

Dada a existência de diversas pesquisas feitas no domínio de sistemas de transporte utilizando a base de dados do ano de 2015 para registros de embarques em ônibus em Fortaleza, que é adotada por este trabalho e explorada em mais detalhes no capítulo de metodologia, surge a necessidade de mencionar alguns dos variados trabalhos feitos, como em Furtado (FURTADO *et al.*, 2017), que através de uma abordagem focada nos dados, procura demonstrar as preferências dos usuários de transportes públicos. Outro trabalho que pode ser mencionado é Caminha (CAMINHA *et al.*, 2016), que descreve um estudo de caso utilizando os dados mencionados acima para compreender os padrões de utilização do sistema de transporte público pelas pessoas, e gerar conhecimento para sugerir intervenções a serem aplicadas à rede de transporte em questão. Ainda utilizando a mesma base de dados, mas com um subdomínio de segurança pública e análise de crimes, pode-se citar Sullivan (SULLIVAN *et al.*, 2017), que avalia as tendências de escolhas de rotas de usuários de sistemas de transporte público e como estas podem refletir na priorização de segurança própria, ao contrário de uma rota ótima para o destino final desejado.

Mais recentemente, no ano de 2021, uma pesquisa que deve ser mencionada pela importância e similaridade a este trabalho é “*Predicting Public Transportation Load to Estimate the Probability of Social Distancing Violations*” (MARTINEZ *et al.*, 2021). Esta pesquisa utiliza de quatro modelos estatísticos (*Poisson*, Binomial negativo, *Poisson* Inflacionada de Zeros e Binomial negativo Inflacionada de zeros) e um modelo de regressão - baseado nas *features* de dia, paradas e linhas de ônibus específicos - para prever a quantidade de passageiros que requisitam a linha de ônibus em um determinado dia e hora. Dessa maneira, consegue contextualizar o estado em que o mundo atualmente vive devido à pandemia causada pelo COVID-19, de forma

a procurar garantir o distanciamento social dentro dos transportes públicos analisados. Em virtude da extensão da própria pesquisa, esta se limitou a uma previsão focada nos dias úteis (segunda-feira à sexta-feira), acusando a erraticidade do comportamento dos passageiros aos finais de semana em tempos de pandemia.

Este trabalho introduz uma modelagem intuitiva e independente do domínio estudado, pois, tirando proveito das características de série temporal presentes no problema, selecionam-se *features* para o modelo que não estão atreladas ao domínio em si. Estes detalhes criam uma base sólida para a comparação dos modelos de *ensemble* através da análise de suas performances nas previsões dos exemplos descritos na secção de metodologia, onde pode-se encontrar uma demonstração detalhada da modelagem e de como os mesmos são avaliados. Pesquisas similares dentro deste domínio foram encontradas, entretanto, nenhuma foi observada explorando tal campo da perspectiva performática de modelos de *ensemble*.

3 METODOLOGIA

Nesta seção, é realizada uma descrição sobre o trabalho experimental proposto. Primeiramente, são descritas a base de dados analisada e quaisquer necessidades de higienização da mesma. Em seguida, são apresentadas as ferramentas utilizadas e sua relação com os dados.

3.1 FERRAMENTAS

Neste trabalho é utilizada a linguagem de programação *Python* com a adição de alguns pacotes e *frameworks* para auxiliar o desenvolvimento dos modelos, o processamento de dados e a apresentação dos mesmos. É importante mencionar algumas ferramentas, como: *pandas*, *sklearn*, *matplotlib* e *numpy* ¹ - todas gratuitas em qualquer tipo de uso e executadas dentro de uma plataforma chamada Anaconda, que permite a emulação de ambientes de desenvolvimento voltados para a área de ciência de dados e aprendizado de máquina.

3.2 BASE DE DADOS

Os dados disponíveis, fornecidos e utilizados na pesquisa, seguem o formato CSV (*Comma Separated Values* ou Valores Separados por Vírgulas) e são arquivos contendo marcações geolocalizadas de validações de usuários. O conjunto de dados empregado nesta pesquisa possui extensa utilização em outros trabalhos científicos como em Ponte (PONTE *et al.*, 2018), Caminha (CAMINHA *et al.*, 2016), Caminha (CAMINHA *et al.*, 2018), (CAMINHA; FURTADO, 2017) que estuda o impacto da mobilidade humana na alocação de recursos policiais, (CAMINHA *et al.*, 2017) que também estuda relações de crime em metrópoles como o trabalho mencionado anteriormente, dentre outros. Na Tabela 1 identifica-se um exemplo dos dados contidos nos arquivos CSV mencionados:

¹ Pandas - <https://pandas.pydata.org/> ; Scikit Learn - <https://scikit-learn.org/stable/index.html>; Matplotlib - <https://matplotlib.org/>; Numpy - <https://numpy.org/>

Tabela 1 – Descrição e exemplificação da organização dos dados utilizados no projeto.

Nome da coluna	Descrição da coluna	Valor da coluna
Identificador linha de ônibus	Número utilizado para identificação da rota seguida pelo ônibus (315, 024, 019, etc. . .)	041
Identificador do veículo	Número para identificação interna do veículo utilizado na rota	67601
Data e Hora	Registro temporal da validação efetuada	30/11/2015 11:30:44
Tipo de validação	Tipo de validação feita, pode ser caracterizada em valores mapeados entre (Inteira, Meia-Estudante, Meia-Idoso, etc. . .)	2
Sentido (Ida e Volta)	Sentido da rota do ônibus atualmente, se o mesmo está indo ou voltando do terminal de partida	V
Latitude	Latitude no momento do embarque / validação do passageiro	-3.76334
Longitude	Longitude no momento do embarque / validação do passageiro	-38.29284
Integração (Sim e Não)	Determina se o passageiro está usando a função de integração do bilhete único ou não	S

Fonte – Elaborada pelo autor

Os dados obtidos englobam 404 linhas de ônibus utilizadas na cidade de Fortaleza no ano de 2015 completo, de janeiro a dezembro. O conjunto de dados completo de 2015, possui 334.969.042 validações em um somatório de todas as linhas de ônibus. As cem linhas com maior volume de embarques representam 218698540, cerca de 65% de todas as validações. Neste trabalho as dez linhas mais utilizadas são apresentadas e possuem ao todo 44.169.389 registros embarques que significam aproximadamente 13% de todas as validações do conjunto de dados.

Foram selecionadas para os testes principais e execuções dos modelos as 100 linhas mais utilizadas, ou seja, as linhas de ônibus com as maiores quantidades de exemplos na base de dados. A decisão foi feita com o pensamento de brevidade e maior foco em linhas mais populares que possivelmente representam os picos e os padrões de uso mais acentuados. As linhas utilizadas como exemplos em representações visuais nas próximas seções do trabalho estão contidas nesse conjunto das 100 linhas mais utilizadas pelos passageiros. De forma mais específica, são utilizadas também com frequência, como exemplos a demonstrarem os resultados neste trabalho, as execuções e implementações feitas sobre a linha 041, sendo umas das 5 linhas


mais utilizadas na base de dados e possuindo os clássicos picos e vales padrões de utilização.

3.3 HIGIENIZAÇÃO E TRANSFORMAÇÃO DOS DADOS

Avaliando os arquivos CSV mencionados nas seções anteriores, foram extraídas informações adicionais para se utilizar no modelo. No arquivo de validação (1) têm-se os dados utilizados para a fabricação dos modelos de aprendizado de máquina. Para cada registro têm-se os valores em questão de: linha de ônibus, data e hora, tipo de validação, latitude, longitude e integração. Utilizando-se de ferramentas como as descritas na seção anterior, é possível extrair mais informações dos dados contidos nesta base, como por exemplo: dos dados de data e hora, pode-se inferir, com precisão, o dia do mês, do ano e o dia da semana. Esses recursos são essenciais para a elaboração dos modelos e agrupamento de dados para a extração de informações.

Ao transformar e agrupar os dados provenientes do arquivo de validação, podem-se obter algumas informações, como o acumulado de validações por hora do dia, como mostra o exemplo:

Figura 10 – Quantidade de embarques por hora, da linha 041 Parangaba/Oliveira Paiva (novembro de 2015).



Fonte – Elaborada pelo autor

A Figura 10 permite perceber os três picos que podem ser observados na maioria das linhas de ônibus mais comumente utilizadas: (1) entre 6:00 e 8:00 horas, (2) entre 11:00 e 13:00

horas e (3) entre 16:00 e 18:00 horas. Essas informações são essenciais para a construção do modelo, servindo como indicadores dos padrões de demanda a se esperar. De forma geral, os dados inicialmente são utilizados para a geração de gráficos e elementos visuais para auxiliar na contextualização do problema do trabalho. Desses dados, alguns tratamentos - como ajuste de tipagem (*float*, *integer*, *date time*, etc) e separação de colunas por responsabilidade - são feitos para facilitar a manipulação e seleção dos *inputs* mais importantes para os modelos de aprendizado de máquina.

3.4 EXEMPLO DE ESTUDO


É necessário, para resolver um problema como este, definir o exemplo a ser considerado, e, no caso deste trabalho, segue-se a seguinte configuração, com um modelo específico por linha de ônibus: dada uma data e hora (compreendendo o dia específico da semana, do mês e do ano), efetua-se a previsão da quantidade de passageiros embarcando nesta linha. Assim, dada a natureza de série temporal da análise em questão, as previsões para este tipo de problema podem ser em uma sequência de horas. Por exemplo, para um modelo prever o embarque de passageiros de um dia inteiro, esse deve, utilizando os dados de treinamento, efetuar vinte e quatro previsões à frente, considerando uma determinada linha de ônibus.

3.5 ENGENHARIA DE *FEATURES*

É necessário analisar os dados obtidos para encontrar características (*features*) nas quais o modelo de aprendizado de máquina deve ponderar ao realizar a previsão do alvo (*target*) em questão. A fundamentação teórica trabalhada previamente auxilia no processo de escolha das *features* mais comumente utilizadas nestes tipos de trabalhos. A definição do *target* é algo direto e simples de se observar: precisa-se prever a quantidade de passageiros efetuando validações, logo, tem-se a quantidade de validações como *target* do projeto.

Data e Hora (*Timestamp* ou Carimbo de Data/Hora) da validação do passageiro: deste dado podem-se extrair diversos outros elementos essenciais para a previsão da quantidade de passageiros embarcando no ônibus. Observa-se a importância desses dados quando tem-se a ilustração dos padrões de embarque durante as horas de um dia.


Figura 11 – Soma total de validações por hora em todo o conjunto de dados no arquivo de validações.



Fonte – Elaborada pelo autor

Percebe-se na Figura 11 (soma total de validações por hora em todo o conjunto de dados no arquivo de validações), que a hora do dia representa os picos e vales de demanda de ônibus. Para representar a hora como uma *feature* no modelo de aprendizado de máquina, deve-se garantir que a natureza cíclica da marcação de hora seja retratada fielmente, ou seja, após 23h59min o relógio reinicia a contagem a partir de meia-noite. Representar este valor apenas como um número inteiro qualquer não simboliza ao modelo a verdadeira característica da *feature*, pois a representação de hora com o número 23 está mais próximo de 00 hora do que de 12 horas (meio-dia). Para resolver esta situação, um cálculo é feito em cima da hora a fim de identificar seu seno e cosseno, transformando-a em 2 dimensões. A combinação de ambos resulta em, matematicamente, representar essa natureza. A Figura 12 ilustra esta combinação.


Figura 12 – Representação da combinação do Seno e Cosseno da Hora do embarque.A) Cosseno da Hora , B) Seno da Hora e C) sendo a representação conjunta de A e B



Fonte – Elaborada pelo autor

Avaliando os picos e vales em cada dia da semana, percebem-se mudanças intrínsecas nos padrões de demanda:

Figura 13 – Sazonalidade de quantidade de embarque de passageiros em dias úteis.



Fonte – Elaborada pelo autor

Figura 14 – Sazonalidade de quantidade de embarque de passageiros em finais de semana.




Fonte – Elaborada pelo autor

Na Figura 13, observa-se o padrão de demanda de ônibus nos dias úteis da semana (de segunda-feira a sexta-feira) e, na Figura 14, o do final de semana (sábado e domingo). Observando essas diferenças, incluir o dado do dia da semana como *feature* torna-se valioso para os modelos.


Continuando a avaliação sobre o *Timestamp*, em uma visão mais ampliada, têm-se os dias relativos do mês (01 a 28, 30 e 31) e suas semanas:

Figura 15 – Sazonalidade de quantidade de embarque de passageiros por dia do mês.



Fonte – Elaborada pelo autor


Figura 16 – Sazonalidade de quantidade de embarque de passageiros por semana do mês.



Fonte – Elaborada pelo autor

Nota-se nas Figuras 15 e 16 de sazonalidade diária, e nas subdivisões de semanas do mês, uma acentuação dos picos e vales esperados nos horários. Como busca-se em um modelo aumentar a qualidade e precisão das previsões, torna-se importante adicionar este dado ao modelo de aprendizado de máquina. Comparativamente, cada mês também possui diferenças entre si em demanda: por exemplo, no calendário letivo brasileiro, julho é um mês de férias escolares, sendo assim, pode-se esperar uma queda natural na demanda. Tal fato pode ser observado no gráfico comparativo:


Figura 17 – Comparativo de quantidade de embarque entre junho e julho de 2015.



Fonte – Elaborada pelo autor

Devido a esta diferença de demanda mês-a-mês, a *feature* referente ao mês em que ocorreu a validação é inserida no modelo. Conforme a avaliação sobre o *Timestamp* das validações de usuário, foi identificada outra forma na qual os padrões esperados de demanda podem se alterar, e uma conclusão simples e direta fora: a ocorrência de dias extraordinários como feriados. Em fevereiro de 2015, o carnaval brasileiro e seu feriado ocorreram nos dias 17 e 18, terça-feira e quarta-feira respectivamente, e avaliando o gráfico abaixo pode-se perceber a importância de feriados para o problema em questão:

Figura 18 – Ilustração da diferença de quantidade de embarque de passageiros no período de feriado de carnaval em fevereiro de 2015.



Fonte – Elaborada pelo autor

Destacados, em barras vermelhas, no gráfico acima estão os dias de feriado do carnaval. Ao comparar esta dupla de terça-feira e quarta-feira de feriado com as outras terças-feiras e quartas-feiras do mesmo mês - dias 6 e 7, 20 e 21, 27 e 28 -, percebe-se uma grande diferença na demanda de ônibus, tendo em vista que a população está, de uma forma geral, utilizando menos o sistema de transporte público. A adição dos feriados é feita ao modelo pela justificativa explicada anteriormente, entretanto, um outro detalhe pode ser percebido no gráfico: a véspera do feriado é igualmente importante para o modelo, pois a segunda-feira que antecede o início de feriado (destacada em verde claro) reflete, também, uma mudança nos padrões de demanda e deve ser inserido como *feature* dos modelos. Por fim, pode-se listar então como *features* escolhidas para o treinamento dos modelos:

- Seno da hora + Cosseno da hora (representado a hora da validação);
- Dia do ano (1 a 366);
- Dia do mês (1 a 31);
- Dia da semana (0 a 6 - domingo a sábado);
- Mês (1 a 12 - janeiro a dezembro);
- Semana do Mês (1 a 4);
- Marcador de feriado (0 ou 1);
- Marcador de véspera de feriado (0 ou 1).

E tem-se como *target* ou alvo final de previsão, a quantidade de passageiros embar-

cando em um determinado exemplo, descrito na secção anterior.

3.6 MODELAGEM PARA APRENDIZADO DE MÁQUINA

Feita a engenharia de *features*, é efetuada a modelagem do problema para aprendizado de máquina seguindo o exemplo/pergunta do problema: quantos passageiros efetuarão a validação - ou seja, o embarque - em uma determinada linha de ônibus, em um dia da semana de domingo a domingo em um intervalo de hora específico? O problema se caracteriza como um de Regressão e, para os modelos a serem treinados, foram utilizadas as seguintes técnicas e comparados os seus resultados de previsão, utilizando as métricas de performance e erros descritos na seção de Fundamentação Teórica:

- *Bagging*;
- *Stacking*;
- *Boosting*.

Foram designados, então, alguns tipos de modelagem para a aplicação de tais técnicas:

- Um modelo por linha de ônibus - Neste caso, a linha não é introduzida como uma *feature* do problema e um modelo é preparado e treinado para cada linha, separadamente;
- Treinamento dos modelos com uma quantidade determinada de dias, semanas ou meses;
- Verificação do quanto seus erros são afetados se aumentarmos o quanto o modelo deve prever à frente, ou como o modelo se comporta ao adicionar ou remover dados de treinamento (Tendo em vista que a unidade de previsão do modelo é a hora do dia, ou seja, um dia de previsões equivale a 24 previsões que o modelo deve efetuar).


4 RESULTADOS

Iniciam-se então os testes realizados na pesquisa, e exemplificam-se alguns resultados feitos com os seguintes detalhamentos: o modelo é treinado com os dados dos meses completos de janeiro, fevereiro e março da linha 041 - PARANGABA / OLIVEIRA PAIVA / PAPICU e então, prevê um dia inteiro escolhido arbitrariamente, ou seja, efetua 24 previsões seguindo o exemplo do problema: prever quantos passageiros vão embarcar em uma determinada linha de ônibus em um determinado dia e hora. Os resultados mostrados em tabelas e gráficos são compostos de médias de dez execuções dos modelos.

Os dados da linha 041 - PARANGABA / OLIVEIRA PAIVA / PAPICU no ano de 2015 foram escolhidos para os testes pois representam o maior fluxo de passageiros, como ilustrado na Figura 19 contendo o somatório de embarques de todo o ano para cada linha:

Figura 19 – Comparativo de quantidade de embarques entre as 50 linhas com mais fluxo.

Em destaque a linha 041 - PARANGABA / OLIVEIRA PAIVA / PAPICU




Fonte – Elaborada pelo autor

Inicialmente, pode-se introduzir como base um modelo de regressão linear. As Figuras 20 e 21, contendo uma previsão do dia 1º de abril de 2015 em um modelo treinado com os dados dos meses de janeiro, fevereiro e março de 2015, ilustram o comportamento de dois modelos lineares (Regressão Linear e *Ridge Regression*, respectivamente) para um problema que se demonstra tipicamente não-linear. Conceitualmente, pode-se explicar um modelo linear


como aquele que tenta traçar uma linha aproximando todos os resultados e previsões, entretanto, devido à natureza não-linear do problema com picos e vales em certos horários, os métodos se mostram pouco efetivos, apesar de identificarem levemente as sazonalidades do problema:

Figura 20 – Gráfico de previsão do dia 1º de abril de 2015 em um modelo treinado com os dados dos meses de janeiro, fevereiro e março de 2015 utilizando Regressão Linear.



Fonte – Elaborado pelo autor

Figura 21 – Gráfico de previsão do dia 1º de abril de 2015 em um modelo treinado com os dados dos meses de janeiro, fevereiro e março de 2015 utilizando *Ridge Regression*.



Fonte – Elaborada pelo autor

Utilizando as métricas de erro, percebe-se também a dificuldade dos modelos de encontrar as variações de valores corretos de previsão, apesar de esboçar um alto *bias* identificando parte das tendências de fluxo esperadas em um dia. Mesmo com o *fine-tuning* utilizando técnicas para encontrar os parâmetros ótimos de configuração (*Grid Search*) e utilizando mais de um modelo para auxiliar nas previsões (*Bagging*), os resultados não possuem grandes melhoras. A Tabela 2 representa a avaliação de performance de alguns modelos lineares, elencados na primeira coluna, ao treinar com os dados de janeiro, fevereiro e março de 2015 e prevendo o dia primeiro de abril para a linha de ônibus 041 - Parangaba / Oliveira Paiva / Papicu.

Tabela 2 – Resultados de métricas de erro em previsões utilizando modelos lineares.

Modelo	R2	RMSE	MAE	MAPE
Regressão Linear	0.436573	326.077500	251.352672	1.430777
Regressão Linear Bagging	0.435876	326.279007	252.229244	1.444632
Ridge Regression	0.475805	319.462070	247.810547	1.357519
SVR	-0.000887	441.433723	354.291421	3.458119

Fonte – Elaborada pelo autor

Aplicam-se, então, modelos não-lineares para buscar uma acurácia maior dentro do


problema. Em uma análise da Figura 22 pode-se perceber que, agora com modelos não-lineares, a linha tracejada representando as previsões do modelo conseguem “compreender” melhor os padrões da linha sólida que ilustram no gráfico os valores reais de quantidade de passageiros embarcando em uma determinada hora. O modelo serve como um limite mínimo de performance, no sentido de que este é um modelo que já pode resolver o problema, mas é necessário um estudo mais aprofundado de técnicas para conseguir previsões melhores. As informações valiosas nesta primeira análise são que o modelo de árvore de decisão já consegue identificar corretamente os vales e picos de demanda de embarque, e pode-se perceber que, dependendo do *target* de previsão, os meses de treinamento influenciam a acurácia do modelo. Em termos de precisão, ainda existe espaço para melhoria e têm-se mais resultados em aplicações abaixo de modelos de *ensemble* mais sofisticados. Na Tabela 3, são elencados os resultados da aplicação do modelo de árvore de decisão.

Tabela 3 – Resultados da previsão com árvore de decisão.

Datas previstas	R2	RMSE	MAE	MAPE
1º de abril	0.935083	109.612716	68.538813	4.462471
5 de maio	0.927124	118.856913	73.152207	6.114476
10 de novembro	0.929843	116.618796	71.343988	6.114476

Fonte – Elaborada pelo autor

Figura 22 – Resultados de métricas de erro para o modelo de árvore de decisão, treinado com janeiro, fevereiro e março de 2015 prevendo: 1º de abril, 5 de maio, 10 de novembro.



Fonte – Elaborada pelo autor


Aplicando a primeira técnica de *ensemble*, pode-se fazer um *Bagging* de árvores de decisão que, diferente do *Random Forest*, outro modelo de bagging de arvores de decisão, as *features* deste *ensemble* não são selecionadas aleatoriamente. Este modelo, como observado na tabela 4, possui resultados melhores apesar de diferenças mínimas em todas as métricas de erro utilizadas. O modelo ainda acompanha as tendências corretamente, mas um leve aumento de precisão pode ser percebido.

Tabela 4 – Resultados da previsão com *Bagging* de árvores de decisão.

Datas previstas	R2	RMSE	MAE	MAPE
1 de abril	0.935757	111.594939	67.526086	2.004410
5 de maio	0.935757	111.594939	67.526086	2.004410
10 de novembro	0.935757	111.594939	67.526086	2.004410

Fonte – Elaborada pelo autor

Figura 23 – Resultados de métricas de erro para o modelo de Bagging de árvores de decisão, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro.



Fonte – Elaborada pelo autor


Aplicando modelos mais sofisticados de *ensemble*, o modelo de *Random Forest* é introduzido à rodada de avaliação, um modelo de *Bagging* que agrega múltiplas árvores de decisão utilizando parte das *features* de forma aleatória para a construção do "comitê", com um funcionamento e processamento internamente diferente de um *Bagging* tradicional de árvores de decisão. Avaliando o modelo com os resultados da tabela 5 e observando a figura 24, percebe-se uma diminuição dos erros dos resultados de até 15.87% na métrica MAE, como no caso da previsão de 5 de maio:

Tabela 5 – Resultados da previsão com *Random Forest*.

Datas previstas	R2	RMSE	MAE	MAPE
1º de abril	0.946974	101.385837	62.850024	1.882971
5 de maio	0.945892	102.414831	63.444497	1.850431
10 de novembro	0.948845	99.581283	61.483071	1.824931

Fonte – Elaborada pelo autor

Figura 24 – Resultados de métricas de erro em previsões para o modelo de Random Forest, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro.



Avaliando as médias dos resultados de cada modelo aplicado até então tem-se a seguinte comparação:

Tabela 6 – Resultados de métricas de erro em previsões utilizando os modelos: árvore de decisão, *Random Forest* Padrão e *Bagging* de arvores de decisão.

Modelo	R2	RMSE	MAE	MAPE
Árvore de decisão	0.930683	115.029475	71.166933	5.563807
Árvore de decisão c/ <i>Bagging</i>	0.935757	111.594939	67.526086	2.00441
<i>Random Forest</i>	0.947237	101.127317	62.592530	1.852777

Fonte – Elaborada pelo autor

Na Tabela 6 percebe-se que os modelos de *ensemble* já trazem melhores performances para o problema em questão. Além disso, como dentre os dois modelos de *ensemble* apresentados até o momento, o modelo de *Random Forest* performa melhor nos casos apresentados, com previsões mais acuradas e boa percepção das tendências do problema. Continuamente, introduzem-se as comparações a um modelo utilizando técnicas de *Stacking*. Inicialmente, uma configuração mais simples deste modelo é feita através da combinação de alguns dos modelos já utilizados anteriormente, com os seguintes atributos:

- Estimadores/Regressores da pilha: Árvore de decisão e Regressão Linear;
- Estimador base/final: *Random Forest*.

Tabela 7 – Resultados de métricas de erro em previsões para o modelo utilizando *Stacking*, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro

Datas previstas	R2	RMSE	MAE	MAPE
1º de abril	0.9518542	96.5636999	61.6450051	7.2814353
5 de maio	0.9530292	95.3538861	61.2924596	6.8192774
10 de novembro	0.9548612	93.5242664	61.044626	6.80554309

Fonte – Elaborada pelo autor

A título de comparação, nomeia-se o modelo da Tabela 7 "*Stacking A*". Tem-se então, até o momento, o modelo de *Stacking A* com as melhores performances, demonstrando melhoria perceptível em relação aos modelos lineares e não-lineares e até mesmo modelos utilizando a técnica de *Bagging*. A seguir, o modelo de *ensemble* avaliado é o de *Boosting* aplicando, mais especificamente, o *extreme Gradient Boosting* (XGBoost):


**Tabela 8 – Resultados de métricas de erro em previsões para o modelo utilizando *extreme Gradient Boosting*, treinado com janeiro, fevereiro e março de 2015 prevendo:
a) 1º de abril b) 5 de maio c) 10 de novembro**

Datas previstas	R2	RMSE	MAE	MAPE
1º de abril	0.975753	68.558869	48.179225	8.151895
5 de maio	0.975753	68.558869	48.179225	8.151895
10 de novembro	0.9755136	68.8942268	48.3677004	8.1011739

Fonte – Elaborada pelo autor

O modelo avaliado na Tabela 8 apresenta uma melhoria de 22% dos modelos anteriores, e a técnica de *Boosting* nas configurações testadas dentro do domínio demonstra boa capacidade de previsão e baixa diferença entre o valor predito e o real.

Figura 25 – Resultados de métricas de erro em previsões para o modelo de *extreme Gradient Boosting*, treinado com janeiro, fevereiro e março de 2015prevendo:
a) 1º de abril b) 5 de maio c) 10 de novembro



Adicionando o modelo de *extreme Gradient Boosting* ao *Stacking A*, onde identifica-se o modelo gerado como *Stacking eGB*:

Tabela 9 – Resultados de métricas de erro em previsões para o modelo *Stacking A* com adição do modelo de *extreme Gradient Boosting*, treinado com janeiro, fevereiro e março de 2015 prevendo: a) 1º de abril b) 5 de maio c) 10 de novembro


Datas previstas	R2	RMSE	MAE	MAPE
1º de abril	0.9759232	68.312428	45.8718145	2.4194544
5 de maio	0.9755911	68.7831207	46.1320623	2.2464805
10 de novembro	0.9756944	68.6394434	45.9907229	2.4241841

Fonte – Elaborada pelo autor

Percebe-se que o modelo *Stacking eGB* é o modelo mais performático nos testes realizados com maior acurácia e menor erro entre os valores previstos e os valores reais. De forma geral, a partir do modelo de árvore de decisão, todos conseguem detectar as tendências do problema de forma adequada, e nos testes seguintes utilizando as técnicas de *ensemble* nota-se, de forma geral, um aumento na precisão das previsões. A seguir algumas ilustrações do melhor modelo efetuando previsões:

Figura 26 – Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro


Stacking eGB - Treinado com os meses de janeiro a outubro - Prevendo primeira semana de novembro



Fonte – Elaborada pelo autor

Figura 27 – Resultados da previsão da primeira semana de dezembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a novembro

Stacking eGB - Treinado com os meses de janeiro a novembro - Prevendo primeira semana de dezembro



Fonte – Elaborada pelo autor

Agrupando os resultados finais, tem-se a seguinte classificação dos modelos, do mais performático ao menos performático.

Tabela 10 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.975694	68.639443	45.990722	2.424184
<i>extreme Gradient Boosting</i>	0.975513	68.894226	48.367700	8.101173
<i>Stacking A</i>	0.954861	93.524266	61.044626	6.805543
<i>Random Forest</i>	0.948845	99.581283	61.483071	1.824931
Árvore de decisão c/ <i>Bagging</i>	0.935757	111.59493	67.526086	2.004410
Árvore de decisão	0.929843	116.61879	71.343988	6.114476

Fonte – Elaborada pelo autor

No apêndice A, pode-se encontrar os resultados comparativos das nove linhas de ônibus com mais fluxo de passageiros, após a linha 041. No apêndice, o modelo mais performático é ilustrado com figuras similares a que pode-se observar neste capítulo de resultados.

Apesar dos resultados apresentados durante este capítulo satisfazerem a proposta da pesquisa, é necessário ser assertivo se os modelos estão, de fato, "aprendendo" e não estão sendo *overfitted*, ou seja, os modelos performam bem no *fit* dos dados de treinamento e teste, mas ao efetuar previsões com dados e exemplos não vistos ainda pelo mesmo, este acaba por performar abaixo do esperado. Pode-se observar que não é o caso nas aplicações abordadas nesta pesquisa, pois todas as previsões apresentadas são com dados não observados pelo modelo e, ainda assim, suas performances permanecem dentro das faixas esperadas.

5 CONCLUSÕES

Durante o trabalho, após estabelecer a modelagem utilizada, são comparados e ilustrados, através dos testes na linha de ônibus 041, os modelos de *ensemble* utilizando técnicas de *Bagging*, *Stacking* e *Boosting*. Na previsão de quantos passageiros embarcam em uma determinada linha de ônibus em um determinado dia e hora, os resultados mostram que os modelos de *ensemble* possuem vantagens acima de modelos que não utilizam estas técnicas. Dentre tais modelos, nota-se ainda que com uma combinação entre as próprias técnicas de *ensemble* existe uma variação em ganhos de performance que pode ser estudada mais profundamente em trabalhos futuros. Especificamente, para o domínio estudado e considerando a modelagem feita, as técnicas de *Stacking* e *Boosting* se provaram mais eficientes com combinações entre si e parametrização adequada.

5.1 CONTRIBUIÇÕES DO TRABALHO

O trabalho consegue apresentar não somente uma avaliação comparativa de alguns modelos de *ensemble* utilizados no domínio de sistemas de transporte público, como também disponibiliza uma engenharia de features extensa e detalhada, exibindo os detalhes em suas avaliações, para o domínio e também como uma modelagem aplicada e compreensiva para execução de máquinas de aprendizado.

5.2 LIMITAÇÕES

Como limitações observadas no trabalho, pode-se citar:

- Quantidade de dados disponível para treinamento - Durante a pesquisa pôde-se perceber que os modelos se comportam de forma instável devido à pouca quantidade de dados disponíveis. Adicionando ou removendo um mês no treinamento do modelo, sua performance pode variar consideravelmente. Pode-se imaginar que tendo apenas o ano de 2015, os modelos têm apenas um exemplo para cada dia do ano, ou seja, o modelo só possui um único exemplo de datas comemorativas ou de meses que possuem naturalmente queda de fluxo como o mês de julho (férias escolares/acadêmicas). Idealmente, uma base de dados maior é desejada;
- Características dos dados disponíveis - Em 2015, ocorreu a implementação do Bilhete Único em Fortaleza - um sistema de integração entre passagens que

permite ao passageiro ingressar em quantos ônibus forem necessários em um período de duas horas, pagando o valor de uma passagem. Como a adesão a este sistema não é instantânea, percebe-se nos dados um crescimento incomum no fluxo de passageiros. Após a estabilização do número de usuários que aderiram ao sistema, o conjunto de dados se torna mais estável e representa de forma mais acurada a verdadeira quantidade de embarques acontecendo no dia-a-dia. Com isso, um conjunto de dados sem esse tipo de fenômeno social pode ser mais bem aproveitado para a pesquisa.

A seguir, uma variação dos testes é executada em prol da transparência sobre como os modelos são afetados pelos dados disponíveis. Para uma primeira observação da influência dos dados nos modelos comparados neste trabalho, é adicionado ao conjunto de treinamento (janeiro, fevereiro e março de 2015), para a previsão do dia primeiro de abril, outros meses de forma arbitrária, com o objetivo de procurar aumentar a precisão dos modelos:

Tabela 11 – Alteração nos dados de treinamento, com o modelo *Stacking eGB*, prevendo o dia primeiro de abril de 2015.

Alterações nos Dados de Treinamento Propostos	R2	RMSE	MAE	MAPE
Adição do mês de outubro aos dados de treinamento	0.958634	87.989018	52.137087	1.974309
Todos os meses de 2015, com exceção de abril	0.972181	74.0225607	46.9233143	9.398773
Todos os meses de 2015	0.970749	76.4389371	46.8897795	7.815207

Fonte – Elaborada pelo autor

Percebe-se que com a alteração dos meses de treinamento o modelo pode variar em até aproximadamente 15% na métrica de MAE. Pode-se caracterizar este fenômeno com o modelo como uma limitação dos dados disponíveis, pois o modelo não possui muitos exemplos de como um dia primeiro de abril se comporta, e procura suas tendências em outros dias ou meses similares.

5.3 TRABALHOS FUTUROS

Esta pesquisa abre espaço para melhorias e expansões em prol da otimização geral sobre o domínio estudado e sobre a própria avaliação dos modelos utilizados. Dentre algumas

sugestões possíveis, foram observados pelo autor como passos adiante da pesquisa e podem ser citados:

- Incrementação e adição de *features* espaciais como latitude e longitude dentro das validações para uma melhoria geral dos modelos e re-avaliação dos mesmos;
- Comparação dos modelos explorados aqui com os de rede neural adequadas para problemas de série temporal como *Long Short Term Memory*;
- Aplicação da estrutura de engenharia de *features* e modelagem em outros domínios - Devido a "imparcialidade" da modelagem genérica, abre-se espaço para outras aplicações com uma natureza comportamental de dados similar. Essencialmente, utilizar a engenharia de features feitas neste trabalho em outros domínios sociais que possuam uma característica temporal adequada ou similar ao do domínio de sistemas de transportes públicos estudados.

REFERÊNCIAS

- ABU-MOSTAFA. Learning from data. Caltech, 2012.
- AMRANE, M.; OUKID, S.; GAGAOUA, I.; ENSAR, T. Breast cancer classification using machine learning. IEEE, 2018.
- BOHANEC, M.; BORŠTNAR, M.; MARKOROBNIK-ŠIKONJA. Explaining machine learning models in sales predictions. Elsevier, 2017.
- BREIMAN, L. Bagging predictors. Springer, 1996.
- CAMINHA, C.; FURTADO, V. Impact of human mobility on police allocation. 2017 IEEE International Conference on Intelligence and Security Informatics (ISI), 2017.
- CAMINHA, C.; FURTADO, V.; PEQUENO, T.; PONTE, C.; MELO, H. P. M.; OLIVEIRA, E. A.; JR, J. S. A. Human mobility in large cities as a proxy for crime. Plos One, 2017.
- CAMINHA, C.; FURTADO, V.; PINHEIRO, V.; SILVA, C. Micro-interventions in urban transportation from pattern discovery on the flow of passengers and on the bus network. IEEE, 2016.
- CAMINHA, C.; FURTADO, V.; PINHEIRO, V.; PONTE, C. Graph mining for the detection of overcrowding and waste of resources in public transport. Springer Nature, 2018.
- CEDER, A.; H.M.WILSON, N. Bus network design. Elsevier Ltd, 1986.
- COOPER, G. F.; F.ALIFERIS, C.; AMBROSINO, R.; ARONIS, J.; G.BUCHANAN, B.; CARU-ANA, R.; J.FINE, M.; GLYMOUR, C.; GORDON, G.; H.HANUSA, B.; E.JANOSKY, J.; MEEK, C.; MITCHELL, T.; RICHARDSON, T.; SPIRTESE, P. An evaluation of machine-learning methods for predicting pneumonia mortality. Elsevier B.V., 1996.
- DIETTERICH, T. G. An experimental comparison of three methods for constructing ensembles of decision trees: Bagging, boosting, and randomization. Kluwer Academic, 1998.
- DISKIN, M. H. Water resources research - definition and uses of the linear regression model. AGUPUBS, 1970.
- FURTADO, V.; FURTADO, E.; CAMINHA, C.; LOPES, A.; DANTAS, V.; PONTE, C.; CAVALCANTE, S. A data-driven approach to help understanding the preferences of public transport users. 2017 IEEE International Conference on Big Data (Big Data), 2017.
- HAUSSLER, D.; KEARNS, M.; SCHAPIRE, R. E. Bounds on the sample complexity of bayesian learning using information theory and the vc dimension. Springer, 1994.
- HELD, M.; KÜNG, L.; ÇABUKOĞLU, E.; PARESCHI, G.; GEORGES, G.; BOULOCHOS, K. Future mobility demand estimation based on sociodemographic information: A data-driven approach using machine learning algorithms. 18th Swiss Transport Research Conference, 2018.
- HO, T. Random decision forests. Proceedings of the Third International Conference on Document Analysis and Recognition, 1995.
- HOFLEITNER, A.; HERRING, R.; BAYEN, A. Arterial travel time forecast with streaming data: A hybrid approach of flow modeling and machine learning. Elsevier, 2012.

- HUANG, F.; XIE, G.; XIAO, R. Research on ensemble learning. IEEE, 2009.
- JAIN, A.; DUIN, R.; MAO, J. Statistical pattern recognition: a review. IEEE, 2000.
- MAIA, G. L.; PONTE, C.; CAMINHA, C.; FURTADO, L.; MELO, H. P.; FURTADO, V. The ubiquitous efficiency of going further: how street networks affect travel speed. arXiv preprint arXiv:2111.07801, 2021.
- MARTINEZ, J.; MUKHOPADHYAY, A.; AYMAN, A.; WILBUR, M.; PUGLIESE, P.; FREUDBERG, D.; GILLIGAN, J.; LASZKA, A.; DUBEY, A. Passenger flow forecast of rail station based on multi-source data and long short term memory network. Vanderbilt University,, 2021.
- MAZZULLA, G.; EBOLI, L. A service quality experimental measure for public transport. University of Calabria – Faculty of Engineering, Department of Territorial Planning, 2006.
- MILLER, J.; HOW, J. P. Predictive positioning and quality of service ridesharing for campus mobility on demand systems. IEEE, 2017.
- MITCHELL, T. **Machine Learning**. [S.l.]: McGraw-Hill Science/Engineering/Math, 1997.
- OPITZ, D.; MACLIN, R. Popular ensemble methods: An empirical study. Journal of Artificial Intelligence Research, 1999.
- POLIKAR, R. Ensemble learning. Springer, Boston, MA, 2012.
- PONTE, C.; CAMINHA, C.; BOMFIM, R.; MOREIRA, R.; FURTADO, V. A temporal clustering algorithm for achieving the trade-off between the user experience and the equipment economy in the context of iot. 2019 8th Brazilian Conference on Intelligent Systems (BRACIS), 2019.
- PONTE, C.; CARMONA, H. A.; OLIVEIRA, E. A.; CAMINHA, C.; NETO, A. S. L.; JR, J. S. A.; FURTADO, V. Tracing contacts to evaluate the transmission of covid-19 from highly exposed individuals in public transportation. Cornell University, 2021.
- PONTE, C.; MELO, H. P. M.; CAMINHA, C.; JR., J. S. A.; FURTADO, V. Traveling heterogeneity in public transportation. Springer Nature, 2018.
- RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. [S.l.]: Prentice Hall, 2009.
- SANTOS, E. M.; SABOURIN, R.; MAUPINB, P. A dynamic overproduce-and-choose strategy for the selection of classifier ensembles. Elsevier Ltd, 2009.
- SCHWAB, P.; SCHÜTTE, A. D.; DIETZ, B.; BAUER, S. Clinical predictive models for covid-19: Systematic study. JMIR Publications, 2020.
- SULLIVAN, D.; CAMINHA, C.; MELO, H. P.; FURTADO, V. Towards understanding the impact of crime on the choice of route by a bus passenger. Springer, 2017.
- TOQUÉ, F.; KHOUADJIA, M.; COME, E.; TREPANIER, M.; OUKHELLOU, L. Short and long term forecasting of multimodal transport passenger flows with machine learning methods. IEEE, 2017.
- TORRES, J. M.; SHIBA, K.; DAOUD, A.; INOUE KOSUKE; KANAMORI, S.; TSUJI, T.; KAMADA, M.; KONDO, K.; KAWACHI, I. Estimating the impact of sustained social participation on depressive symptoms in older adults. Wolters Kluwer, 2017.

WANG, X.; HUANG, L.; HUANG, H.; LI, B.; XIA, Z.; LI, J. An ensemble learning model for short-term passenger flow prediction. Hindawi, 2020.

WOLPERT, D. Stacked generalization. ELSEVIER, 1992.

ZHANG, J.; SHEN, D.; TU, L.; ZHANG, F.; XU, C.; WANG, Y.; TIAN, C.; LI, X.; HUANG, B.; LI, Z. A real-time passenger flow estimation and prediction method for urban bus transit systems. IEEE, 2017.

ZHANG, Z.; WANG, C.; GAO, Y.; CHEN, Y.; CHEN, J. Passenger flow forecast of rail station based on multi-source data and long short term memory network. IEEE, 2020.

APÊNDICES

APÊNDICE A – Resultados do modelos aplicados nas linhas de ônibus mais utilizadas


No capítulo de resultados, foram apresentadas as performances e previsões feitas para a linha 041 PARANGABA / OLIVEIRA PAIVA / PAPICU, sendo esta a linha de ônibus com maior fluxo de passageiros na região metropolitana de Fortaleza. A título de evidenciar mais resultados dos modelos apresentados, este apêndice apresenta as métricas de erro e performance das outras nove linhas com maior fluxo.

Tabela 12 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 045 CONJUNTO CEARÁ / PAPICU / MONTESE.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.969671	76.580486	48.557588	7.732391
<i>extreme Gradient Boosting</i>	0.964960	82.480727	52.756197	18.022730
<i>Stacking A</i>	0.932417	114.536693	64.448119	9.636443
<i>Random Forest</i>	0.928086	118.132569	65.815449	33.186133
Árvore de decisão c/ <i>Bagging</i>	0.926792	119.220334	68.214165	31.631346
Árvore de decisão	0.874450	156.112711	81.330559	26.080966

Fonte – Elaborada pelo autor

Figura 28 – linha 45 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro




Fonte – Elaborada pelo autor

Tabela 13 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 003 IPARANA / VIA PARQUE LEBLON.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.976542	65.056075	42.055249	7.606880
<i>extreme Gradient Boosting</i>	0.978463	62.338209	41.288045	10.585571
<i>Stacking A</i>	0.943518	100.933412	61.710547	3.296366
<i>Random Forest</i>	0.952987	92.097728	59.416148	15.437731
Árvore de decisão c/ <i>Bagging</i>	0.949032	95.898166	62.246073	13.702251
Árvore de decisão	0.904240	131.428535	77.514116	0.165029

Fonte – Elaborada pelo autor

Figura 29 – linha 003 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro




Fonte – Elaborada pelo autor

Tabela 14 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 042 ANTÔNIO BEZERRA / FRANCISCO SÁ / PAPICU.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.969334	77.152782	46.728209	6.966339
<i>extreme Gradient Boosting</i>	0.970675	75.453398	48.250169	17.099175
<i>Stacking A</i>	0.946871	101.546736	56.619959	8.880667
<i>Random Forest</i>	0.935487	111.898244	59.071385	25.649128
Árvore de decisão c/ <i>Bagging</i>	0.926925	119.108632	63.090935	24.928334
Árvore de decisão	0.872166	157.491109	79.046599	24.881756

Fonte – Elaborada pelo autor

Figura 30 – linha 42 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro




Fonte – Elaborada pelo autor

Tabela 15 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 051 Grande Circular I.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.947406	85.161487	51.977115	16.410454
<i>extreme Gradient Boosting</i>	0.945993	86.304097	51.623969	21.973282
<i>Stacking A</i>	0.947058	85.424247	59.978310	9.412865
<i>Random Forest</i>	0.916687	107.183062	64.790237	26.717551
Árvore de decisão <i>c/ Bagging</i>	0.927299	100.133052	63.700064	19.535523
Árvore de decisão	0.839085	147.522800	80.921781	20.404389

Fonte – Elaborada pelo autor

Figura 31 – linha 51 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro




Fonte – Elaborada pelo autor

Tabela 16 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 052 GRANDE CIRCULAR II.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.947066	77.940761	47.122009	3.749560
<i>extreme Gradient Boosting</i>	0.945013	79.443028	49.328510	14.657616
<i>Stacking A</i>	0.917441	97.336735	58.280393	12.047728
<i>Random Forest</i>	0.875372	119.597540	65.791426	33.865891
Árvore de decisão <i>c/ Bagging</i>	0.873627	120.434576	67.784954	29.565412
Árvore de decisão	0.796055	152.962800	82.341220	23.199427

Fonte – Elaborada pelo autor

Figura 32 – linha 52 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro




Fonte – Elaborada pelo autor

Tabela 17 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 024 ANTÔNIO BEZERRA / LAGOA / UNIFOR.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.976078	62.385102	40.251579	3.295476
<i>extreme Gradient Boosting</i>	0.974500	64.413141	42.994035	9.406112
<i>Stacking A</i>	0.936893	101.300087	54.153479	13.157464
<i>Random Forest</i>	0.944147	95.323390	54.078580	13.755050
Árvore de decisão c/ <i>Bagging</i>	0.937226	101.063106	56.739505	14.896495
Árvore de decisão	0.893464	131.649332	67.348070	14.045473

Fonte – Elaborada pelo autor

Figura 33 – linha 24 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro




Fonte – Elaborada pelo autor

Tabela 18 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 076 CONJUNTO CEARÁ / ALDEOTA / PAPICU.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.977542	54.686400	33.324188	9.299029
<i>extreme Gradient Boosting</i>	0.977362	54.909782	34.456098	13.031567
<i>Stacking A</i>	0.954395	77.846861	46.602569	10.548490
<i>Random Forest</i>	0.945497	85.191585	49.419779	16.953275
Árvore de decisão c/ <i>Bagging</i>	0.943017	87.116699	51.067944	18.284408
Árvore de decisão	0.928236	97.707498	55.568754	10.744182

Fonte – Elaborada pelo autor

Figura 34 – linha 76 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro




Fonte – Elaborada pelo autor

Tabela 19 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 026 ANTÔNIO BEZERRA / MESSEJANA.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.965904	71.195098	46.517381	6.152384
<i>extreme Gradient Boosting</i>	0.970461	66.269885	45.073126	10.901766
<i>Stacking A</i>	0.942020	92.817846	56.750618	15.412086
<i>Random Forest</i>	0.942479	92.473195	54.698976	17.544129
Árvore de decisão c/ <i>Bagging</i>	0.936910	96.850536	56.227288	16.729584
Árvore de decisão	0.916442	111.453004	64.972817	14.127268

Fonte – Elaborada pelo autor

Figura 35 – linha 26 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro




Fonte – Elaborada pelo autor

Tabela 20 – Classificação dos resultados de métricas de erro em previsões dos modelos utilizados na pesquisa, treinados com janeiro, fevereiro e março de 2015 e prevendo o dia 10 de novembro para a linha 044 PARANGABA / PAPICU / MONTESE.

Modelo	R2	RMSE	MAE	MAPE
<i>Stacking eGB</i>	0.970111	62.175956	42.901922	2.805294
<i>extreme Gradient Boosting</i>	0.970148	62.139214	43.357706	8.820434
<i>Stacking A</i>	0.943086	85.788417	50.964240	1.721993
<i>Random Forest</i>	0.949786	80.583947	50.274433	7.870854
Árvore de decisão c/ <i>Bagging</i>	0.945789	83.737849	53.193272	9.232379
Árvore de decisão	0.901131	112.932172	64.811614	6.794839

Fonte – Elaborada pelo autor

Figura 36 – linha 44 - Resultados da previsão da primeira semana de novembro de 2015, no modelo *Stacking eGB* treinado com os meses de janeiro a outubro



Fonte – Elaborada pelo autor